



ARISTOTLE
UNIVERSITY
OF THESSALONIKI

3η Εργασία

Υπολογιστική Νοημοσύνη

Παπαδάκης Κωνσταντίνος Φώτιος
ΑΕΜ: 10371

Αριστοτέλειο Πανεπιστήμιο Θεσσαλονίκης
Τμήμα Ηλεκτρολόγων Μηχανικών και Μηχανικών Υπολογιστών
1 Αυγούστου 2025

Περιεχόμενα

1	Εισαγωγή	2
2	Διαχωρισμός δεδομένων	2
3	Εκπαίδευση	2
4	Αποτελέσματα	3
5	Συμπεράσματα	8
5.1	Χρόνος εκπαίδευσης	8
5.2	Μορφή εξόδου	8
5.3	Διαμέριση χώρου εισόδου	8
5.4	Υπερ-εκπαίδευση	8
6	Εφαρμογή σε dataset με υψηλή διαστασιμότητα	9
6.1	Ανάλυση προβλήματος	9
6.2	Διαγράμματα όλων των μοντέλων	9
6.3	Διαγράμματα βέλτιστου μοντέλου	10
6.4	Σχολιασμός αποτελεσμάτων	14

1 Εισαγωγή

2 Διαχωρισμός δεδομένων

Ξεκινάμε διαχωρίζοντας τα δεδομένα μας σε τρία σύνολα.

- **Train set:** Το σύνολο εκπαίδευσης (60% των δεδομένων). Είναι το σύνολο με το οποίο εκπαιδεύουμε το μοντέλο μας.
- **Checking/Validation set:** Το σύνολο επικύρωσης (20% των δεδομένων). Πάνω σε αυτό ελέγχουμε αν τα διαμορφωμένα κατά την εκπαίδευση βάρη είναι ικανά να γενικευτούν σε νέα δεδομένα.
- **Test set:** Το σύνολο ελέγχου (20% των δεδομένων). Με αυτό υπολογίζουμε την απόδοση του μοντέλου μας.

3 Εκπαίδευση

Κατά την εκπαίδευση των μοντέλων μας χρησιμοποιούμε τον παρακάτω πίνακα μέσω του οποίου αναθέτουμε διαφορετικό αριθμό συναρτήσεων συμμετοχής και διαφορετική μορφή εξόδου ανά μοντέλο.

Μοντέλο	Συναρτήσεις συμμετοχής	Μορφή εξόδου
TSK_model_1	2	Singleton (constant)
TSK_model_2	3	Singleton (constant)
TSK_model_3	2	Polynomial (linear)
TSK_model_4	3	Polynomial (linear)

Πίνακας 1: Πίνακας μοντέλων

Η εκτίμηση της απόδοσης των μοντέλων γίνεται μέσω των μετρικών RMSE (Root Mean Square Error), NMSE (Normalized Mean Squared Error), NDEI (Normalized Data Error Index) και R^2 (Coefficient of Determination).

$$MSE = \sum_{i=1}^N (y_i - \hat{y}_i)^2 \quad (1)$$

$$RMSE = \sqrt{MSE} \quad (2)$$

$$R^2 = 1 - \frac{\sum_{i=1}^N (y_i - \hat{y}_i)^2}{\sum_{i=1}^N (y_i - \bar{y})^2} \quad (3)$$


$$NMSE = \frac{MSE}{\sum_{i=1}^N (y_i - \bar{y})^2} \quad (4)$$

$$NDEI = \sqrt{NMSE} \quad (5)$$


όπου y_i είναι η πραγματική έξοδος, $\hat{y}_i$ η προβλεπόμενη έξοδος, $\bar{y}$ ο μέσος όρος των πραγματικών εξόδων και N το πλήθος των παρατηρήσεων.

4 Αποτελέσματα


Ακολουθούν οι γραφικές παραστάσεις των learning curves και των συναρτήσεων συμμετοχής για κάθε είσοδο του dataset μας. Σημαντικό είναι να αναφερθεί εδώ πως τα αποτελέσματα έχουν random seed 0 για αναπαραγωγιμότητα.




Σχήμα 1: Learning Curve - TSK_model_1




Σχήμα 2: Συναρτήσεις συμμετοχής - TSK_model_1




Σχήμα 3: Learning Curve - TSK_model_2




Σχήμα 4: Συναρτήσεις συμμετοχής - TSK_model_2




Σχήμα 5: Learning Curve - TSK_model_3



Σχήμα 6: Συναρτήσεις συμμετοχής - TSK_model_3



Σχήμα 7: Learning Curve - TSK_model_4



Σχήμα 8: Συναρτήσεις συμμετοχής - TSK_model_4

Στη συνέχεια ακολουθεί ο πίνακας με τις μετρικές απόδοσης των μοντέλων μας.

Μοντέλο	Χρόνος εκπαίδευσης (s)	RMSE	NMSE	NDEI	R ²
TSK_model_1	0.87016	3.8397	0.3379	0.58129	0.99888
TSK_model_2	8.7397	3.5005	0.28084	0.52994	0.99907
TSK_model_3	3.2903	2.6932	0.16623	0.40771	0.99945
TSK_model_4	179.4	3.9961	0.36598	0.60496	0.99878

Πίνακας 2: Πίνακας αποτελεσμάτων εκπαίδευσης

Τα αποτελέσματα αντικατοπτρίζουν την απόδοση των μοντέλων μας στο test set. Παρατηρούμε πως το σφάλμα είναι μεγαλύτερο από το σφάλμα επικύρωσης, το οποίο είναι και λογικό.

5 Συμπεράσματα

5.1 Χρόνος εκπαίδευσης

Παρατηρείται αύξηση του χρόνου εκπαίδευσης όταν:

- Αυξάνεται ο αριθμός των συναρτήσεων συμμετοχής.
- Αυξάνεται η πολυπλοκότητα της μορφής εξόδου (από σταθερή σε πολυωνυμική).

Ιδιαίτερα στην περίπτωση του μοντέλου TSK_model_4, ο χρόνος εκπαίδευσης είναι σημαντικά μεγαλύτερος σε σχέση με όλα τα υπόλοιπα μοντέλα.

5.2 Μορφή εξόδου

Η μορφή εξόδου καθορίζει στο σφάλμα εκπαίδευσης και επικύρωσης. Με έξοδο Polynomial το σφάλμα είναι ορατά μικρότερο από αυτό με έξοδο Singleton, ακόμα και από τις πρώτες εποχές της εκπαίδευσης.

5.3 Διαμέριση χώρου εισόδου

Οι περισσότερες συναρτήσεις συμμετοχής (3 αντί για 2) φαίνεται να επηρεάζουν το αρχικό σφάλμα επικύρωσης και την πορεία που αυτό διαγράφει. Συγκεκριμένα φαίνεται να σημειώνει μια αρχική αύξηση πρώτου αρχίζει να μειώνεται και ξεκινάει από αρκετά μεγαλύτερη τιμή σε σχέση με τα μοντέλα με 2 συναρτήσεις συμμετοχής.

5.4 Υπερ-εκπαίδευση

Και στα τέσσερα μοντέλα το σφάλμα εκπαίδευσης είναι μικρότερο από το σφάλμα επικύρωσης δεν παρατηρούμε ακόμα ιδιαίτερη υπερ-εκπαίδευση όμως αξίζει να σημειωθεί η αύξηση του Validation error στο μοντέλο TSK_model_3, με την πάροδο των εποχών. Σε αυτή τη περίπτωση το μοντέλο μας εξειδικεύεται στα δεδομένα εκπαίδευσης οδηγώντας σε αύξηση του σφάλματος επικύρωσης.

6 Εφαρμογή σε dataset με υψηλή διαστασιμότητα


Η εύρεση των πιο σημαντικών χαρακτηριστικών του dataset μας επιτρέπει να απλοποιήσουμε την διαδικασία της εκπαίδευσης έτσι ώστε να είναι εκτελέσιμη εντός ρεαλιστικού χρονικού πλαισίου. Μέσω της μεθόδου Relieff επιτυγχάνουμε να περιορίσουμε τον αριθμό των χαρακτηριστικών σε 5, 10, 15 και 20 αντίστοιχα, και σε κάθε περίπτωση δοκιμάζουμε διαφορετικές ακτίνες επιρροής των clusters.

6.1 Ανάλυση προβλήματος

Το συγκεκριμένο πρόβλημα παλινδρόμησης χρησιμοποιεί το Superconductivity dataset απο το UCI Repository, το οποίο αποτελείται από 81 χαρακτηριστικά. Ο αριθμός αυτών των χαρακτηριστικών οδηγεί σε 2^{81} κανόνες στην περίπτωση που διαμερίζουμε το χώρο εισόδου σε δύο ασαφή σύνολα. Έτσι είναι αποθαρρυντική η απόπειρα εργασίας πάνω στο μη προεπεξεργασμένο dataset. Για αυτό χρησιμοποιούμε τον αλγόριθμο Relieff, ο οποίος χρησιμοποιεί k-nearest-neighbors και επιστρέφει δύο πίνακες. Έναν με τα πιο σημαντικά χαρακτηριστικά και έναν με τα βάρη τους. Για αυτήν την θα αγνοήσουμε τα βάρη αξιοποιώντας μόνο τα σημαντικά χαρακτηριστικά.

6.2 Διαγράμματα όλων των μοντέλων


Διενεργώντας k-fold cross-validation σε όλους τους συνδυασμούς ακτίνας, αριθμού σημαντικών χαρακτηριστικών σχεδιάζουμε την τιμή του RMSE σε σχέση με τον αριθμό των σημαντικών χαρακτηριστικών(για δεδομένη ακτίνα).



Σχήμα 9: RMSE VS Number of Features

Έπειτα αναπαριστούμε τον αριθμό των κανόνων που προκύπτουν σε σχέση με τον

αριθμό σημαντικών χαρακτηριστικών και την ακτίνα επιρροής των clusters.



Σχήμα 10: RMSE VS Number of Rules


Μέσω αυτής της διαδικασίας μπορούμε να προχωρήσουμε στην εκπαίδευση του μοντέλου με τις βέλτιστες παραμέτρους χαρακτηριστικών και ακτίνας.

Results

Minimum RMSE: 14.1293 at Features: 20, Radius: 0.40


6.3 Διαγράμματα βέλτιστου μοντέλου

Η πρώτη γραφική παράσταση του βέλτιστου μοντέλου περιλαμβάνει την καμπύλη εκμάθησης με τα σφάλματα επικύρωσης και εκμάθησης.




Σχήμα 11: Best Model Learning Curve

Έπειτα μέσω ενός scatter plot αποσκοπούμε στην αποτίμηση του πόσο κοντά είναι οι πραγματικές τιμές σε σχέση με τις προβλέψεις.



Σχήμα 12: Best Model True Vs Predicted



Σχήμα 13: Best Model True Vs Predicted


Στο τέλος του κώδικα, τυπώνουμε τις μετρικές απόδοσης του βέλτιστου μοντέλου. Αυτές είναι:

Performance metrics
Final RMSE on test set: 15.2731
Final NMSE on test set: 0.1996
Final NDEI on test set: 0.4468
Final R^2 on test set: 0.8004
Final number of Rules: 10

Συγκεκριμένα οι πληροφορίες που μας δίνουν αυτές οι μετρικές είναι:

- **RMSE:** Οι προβλέψεις του μοντέλου αποκλίνουν κατά μέσο όρο 15.2731 μονάδες από τις πραγματικές τιμές.
- **NMSE:** Τι μοντέλο αδυνατεί να εξηγήσει το 19.96% της διακύμανσης των δεδομένων.
- **NDEI:** Η αναλογία του RMSE προς την τυπική απόκλιση των δεδομένων. Η τιμή 0.4468, δείχνει ότι το μέσο σφάλμα του μοντέλου είναι 44.68% της τυπικής απόκλισης των δεδομένων. Έτσι παρατηρούμε ότι το σφάλμα είναι σχετικά μικρό σε σχέση με την μεγάλη διακύμανση των δεδομένων και συνεπώς το μοντέλο έχει καλή απόδοση.
- **R^2 :** Το μοντέλο εξηγεί το 80.04% της διακύμανσης των δεδομένων.

Τέλος δοκιμάσαμε να αυξήσουμε τις εποχές (από 45 -> 100) για να δούμε αν το μοντέλο μας οδηγείται σε over-fitting.



Σχήμα 14: Best Model Learning Curve - Extended

Μπορούμε να δούμε ξεκάθαρα ότι κοντά στις 70 εποχές, ενώ το training error μειώνεται ομαλά το validation error παρουσιάζει ορατή αστάθεια και σημαντική αύξηση ανά περιόδους που οφείλεται στην υπερ-εξειδίκευση του μοντέλου στα training data και την αδυναμία γενίκευσης.

6.4 Σχολιασμός αποτελεσμάτων

Ως επί των πλείστων η αύξηση του αριθμού των χαρακτηριστικών οδηγεί στην μείωση του σφάλματος. Εξαίρεση αποτέλεσε η ακτίνα 0.2 η οποία έδειχνε να επωφελείται είτε από πολύ λίγα χαρακτηριστικά είτε από πολλά χαρακτηριστικά, χάνοντας ευστοχία στις ενδιάμεσες τιμές.

Γενικά τα αποτελέσματα έδειξαν ότι στο μικρότερο σφάλμα οδηγούμαστε με μεσαίο αριθμό κανόνων, κοντά στους 10. Όμως αν και οι 10 κανόνες σημείωσαν το ελάχιστο RMSE, οι 5 κανόνες ήταν σταθερά χαμηλά σε αντίθεση με τους 10 των οποίων η διακύμανση ήταν μεγαλύτερη.

Τέλος, στην περίπτωση που θέλαμε να προσεγγίσουμε το συγκεκριμένο πρόβλημα με grid partitioning θα είχαμε 20 χαρακτηριστικά και 2 ή 3 ασαφή σύνολα. Αυτό

θα οδηγούσε σε 2^{20} ή 3^{20} κανόνες, δηλαδή 1,048,576 ή 3,486,784,401 κανόνες. Η μέθοδος subtractive clustering δημιουργεί κανόνες μόνο εκεί που αναγνωρίζει ότι υπάρχουν δεδομένα. Έτσι αποφεύγουμε την ανάγκη υπολογισμού n-διάστατων κελιών του πλέγματος ή πλειονότητα των οποίων δεν θα περιέχουν δεδομένα. Εν τέλει καταλήγουμε σε 10 κανόνες, ασύγκριτα λιγότερους από ότι αν χρησιμοποιούσαμε grid partitioning.