



ARISTOTLE
UNIVERSITY
OF THESSALONIKI

4η Εργασία

Υπολογιστική Νοημοσύνη

Παπαδάκης Κωνσταντίνος Φώτιος
ΑΕΜ: 10371

Αριστοτέλειο Πανεπιστήμιο Θεσσαλονίκης
Τμήμα Ηλεκτρολόγων Μηχανικών και Μηχανικών Υπολογιστών
3 Αυγούστου 2025

Περιεχόμενα

1	Εισαγωγή	2
2	Απλό Dataset	2
	2.1 Γραφικές Παραστάσεις	2
	2.2 Σχολιασμός Αποτελεσμάτων	6
3	Dataset υψηλής διαστασιμότητας	7
	3.1 Επιλογή Βέλτιστων Παραμέτρων	7
	3.2 Βέλτιστο Μοντέλο	10
	3.3 Σχολιασμός Αποτελεσμάτων	13

1 Εισαγωγή


Στην τελευταία εργασία του μαθήματος θα ασχοληθούμε με την χρήση TSK (Takagi Sugeno Kang) μοντέλων προκειμένου να ταξινομήσουμε δύο διαφορετικά Datasets. Στη πρώτη περίπτωση εξετάζουμε την διαδικασία εκπαίδευσης ενώ στη δεύτερη εμβαθύνουμε προεπεξεργάζοντας τα δεδομένα και δοκιμάζοντας μεθόδους βελτιστοποίησης του μοντέλου μας.


2 Απλό Dataset

Το πρώτο ασαφές νευρωνικό δίκτυο μας θα το εκπαιδεύσουμε πάνω στο “Haberman’s Survival” Dataset του UCI repository, το οποίο αποτελείται από 306 samples και 3 χαρακτηριστικά.


2.1 Γραφικές Παραστάσεις

Αρχικά θα εξετάσουμε τις συναρτήσεις συμμετοχής των χαρακτηριστικών μας. Από την μία πλευρά έχουμε τις class independent συναρτήσεις συμμετοχής δημιουργήθηκαν από την συνάρτηση **genfis()** αυτόματα.







Από την άλλη πλευρά, έχουμε τις class dependent συναρτήσεις συμμετοχής, οι οποίες δημιουργήθηκαν χειροκίνητα μέσω των clusters που δημιουργήσαμε από τα training data κάνοντας χρήση της συνάρτησης `subclust()`.



Η καμπύλη εκπαίδευσης των τεσσάρων μοντέλων φαίνεται παρακάτω. Το class independent μοντέλο με ακτίνα 0.2 είναι το πιο αναξιόπιστο με τους λιγότερους κανόνες. Το σφάλμα εκπαίδευσης είναι αρκετά χαμηλό, όμως το σφάλμα επικύρωσης είναι εξαιρετικά υψηλό και ασταθές. Όλα τα υπόλοιπα μοντέλα αρκετά καλή απόδοση.



Σχήμα 1: Class Independent Learning Curves



Σχήμα 2: Class Dependent Learning Curves

Τέλος έχουμε τους πίνακες με τις ειδικές πληροφορίες κάθε μοντέλο, οι οποίοι τυπώνονται από το πρόγραμμα **classification.m** στο τέλος κάθε επανάληψης του βρόγχου που διατρέχει όλες τις ακτίνες. Για βαθύτερη ανάλυση εμπλουτίζω τη λίστα ακτινών με 0.4, 0.6 σε συνδυασμό με τις ήδη υπάρχουσες 0.2 και 0.8 μόνο στο

πρόγραμμα, για να διατηρήσω συνοπτική την παρουσίαση των αποτελεσμάτων. Επίσης αύξησα τον αριθμό εποχών στις 100 για να είναι πιο εμφανή φαινόμενα όπως overfitting και underfitting.

Πίνακας 1: Model 1 – Class Independent, Radius = 0.20

Training RMSE	0.206935
Checking RMSE	2.0836
Number of Rules	20
Error Matrix	$\begin{bmatrix} 34 & 11 \\ 11 & 5 \end{bmatrix}$
Overall Accuracy (OA)	0.6393
Producer's Accuracy (PA)	0.7556, 0.3125
User's Accuracy (UA)	0.7556, 0.3125
Kappa ($\hat{K}$)	0.4117

Πίνακας 2: Model 2 – Class Independent, Radius = 0.80

Training RMSE	0.383046
Checking RMSE	0.411869
Number of Rules	3
Error Matrix	$\begin{bmatrix} 41 & 15 \\ 4 & 1 \end{bmatrix}$
Overall Accuracy (OA)	0.6885
Producer's Accuracy (PA)	0.7321, 0.2000
User's Accuracy (UA)	0.9111, 0.0625
Kappa ($\hat{K}$)	0.4919

Πίνακας 3: Model 3 – Class Dependent, Radius = 0.20

Training RMSE	0.205616
Checking RMSE	0.528371
Number of Rules	48
Error Matrix	$\begin{bmatrix} 42 & 14 \\ 3 & 2 \end{bmatrix}$
Overall Accuracy (OA)	0.7213
Producer's Accuracy (PA)	0.7500, 0.4000
User's Accuracy (UA)	0.9333, 0.1250
Kappa ($\hat{K}$)	0.5454

Πίνακας 4: Model 4 – Class Dependent, Radius = 0.80

Training RMSE	0.381204
Checking RMSE	0.414959
Number of Rules	8
Error Matrix	$\begin{bmatrix} 44 & 12 \\ 1 & 4 \end{bmatrix}$
Overall Accuracy (OA)	0.7869
Producer's Accuracy (PA)	0.7857, 0.8000
User's Accuracy (UA)	0.9778, 0.2500
Kappa ($\hat{K}$)	0.6523

2.2 Σχολιασμός Αποτελεσμάτων

Από τις γραφικές παραστάσεις συμπεραίνουμε ότι η μικρότερη ακτίνα δείχνει να έχει χαμηλό σφάλμα εκπαίδευσης όμως γενικεύει πολύ χειρότερα από ότι μια μεγαλύτερη. Παράλληλα διαμορφώνει πολλούς κανόνες λόγω των μικρών clusters που δημιουργούνται έτσι μπορούμε να πούμε ότι πάρα πολλοί κανόνες μπορούν να οδηγήσουν σε overfitting όπως και παρατηρούμε πιο έντονα στα μοντέλα με πολύ χαμηλή ακτίνα. Να σημειωθεί ότι και τα μοντέλα με μεγάλη ακτίνα παρουσιάζουν overfitting, όμως σε μικρότερο βαθμό και πιο σταδιακά, μετά από περισσότερες εποχές.

Επιπλέον, όταν κοιτάμε τις συναρτήσεις συμμετοχής των class dependent σε σχέση με τις class independent, παρατηρούμε ότι οι class dependent συναρτήσεις είναι

πιο απλωμένες στο χώρο και ταυτόχρονα περισσότερες διότι συνδυάζουν τους μεμονωμένους κανόνες από την επιμέρους class-wise δημιουργία κανόνων.

Εν κατακλείδι, μερικές προτάσεις για βελτίωση της σχεδίασης του τμήματος υπόθεσης είναι:

- Προσθήκη βαρών στους κανόνες για να δώσουμε μεγαλύτερη σημασία σε κάποιους κανόνες κατά την ταξινόμηση.
- Χρήση διαφορετικών μορφών συναρτήσεων συμμετοχής που μπορεί να περιγράφουν καλύτερα τα δεδομένα.
- Ξεχωριστό μέγεθος ακτίνας επιρροής για κάθε cluster ανάλογα με την κατανομή των δεδομένων.

3 Dataset υψηλής διαστασιμότητας

Μεταβαίνοντας στο δεύτερο στάδιο της εργασίας, θα ασχοληθούμε με το “Epileptic Seizure Recognition” Dataset του UCI repository, το οποίο αποτελείται από 11500 samples και 178 χαρακτηριστικά, όταν αφαιρούμε τον κωδικό της πρώτης στήλης. Όπως στην τρίτη εργασία του μαθήματος, θα προεπεξεργαστούμε τα δεδομένα αυτά επιλέγοντας συγκεκριμένο αριθμό σημαντικότερων χαρακτηριστικών. Έπειτα για διαφορετικές ακτίνες των clusters θα επιλέξουμε τις βέλτιστες παραμέτρους μέσω k-fold cross validation και τέλος εκπαιδεύσουμε το βέλτιστο μοντέλο για να το εξετάσουμε.

3.1 Επιλογή Βέλτιστων Παραμέτρων


Οι πίνακες για όλες τις παραμέτρους που εξετάσαμε είναι ο εξής:

Features	Radius	AvgRMSE	AvgRules	AvgOA
5	0.20	1.1239	5.0	0.3200
5	0.40	1.1321	3.0	0.2939
5	0.60	1.2140	3.0	0.2704
5	0.80	1.4177	1.0	0.2006
10	0.20	1.0740	4.8	0.3780
10	0.40	1.0970	3.0	0.3039
10	0.60	1.2092	3.0	0.2961
10	0.80	1.4176	1.0	0.2009
15	0.20	1.0529	4.0	0.3859
15	0.40	1.0821	3.0	0.3209
15	0.60	1.1422	2.6	0.2949
15	0.80	1.4194	1.0	0.2012
20	0.20	1.0367	4.0	0.4167
20	0.40	1.0707	3.0	0.3403
20	0.60	1.1404	2.6	0.3033
20	0.80	1.4215	1.0	0.2010

Πίνακας 5: Αποτελέσματα Επιλογής Παραμέτρων (k-fold cross validation)


Minimum OA: 0.4167 at Features: 20, Radius: 0.20

Παράλληλα μπορούμε να διακρίνουμε μερικά μοτίβα μέσω των παρακάτω διαγραμμάτων. Συγκεκριμένα, Το σφάλμα μειώνεται όταν πέφτει η ακτίνα των clusters, πιθανώς διότι τα δεδομένα είναι διανεμημένα σε μικρότερα clusters.



Σχήμα 3: RMSE vs Cluster Radius


Επίσης, στα περισσότερα παραδείγματα αυξάνοντας τα σημαντικά χαρακτηριστικά που λαμβάνουμε υπόψη μειώνεται το σφάλμα. Η γενική εικόνα παρουσιάζει ένα dataset το οποίο δύσκολα περιορίζεται σε λίγα χαρακτηριστικά ενώ φαίνεται να έχει αρκετά πυκνή κατανομή δεδομένων και επωφελείται από μικρότερα clusters.




Σχήμα 4: RMSE vs Number of Features

3.2 Βέλτιστο Μοντέλο

Ενδεικτικά παραθέτουμε την μορφή των συναρτήσεων συμμετοχής πριν και μετά την εκπαίδευση του βέλτιστου μοντέλου. Παρατηρούμε πως οι συναρτήσεις συμμετοχής ταυτίζονται όταν δημιουργούνται όμως έπειτα από την εκπαίδευση του μοντέλου η κάθε μία έχει αλλάξει πλάτος και κέντρο αν και κατά κύριο λόγο μένουν όλες γύρω από κοινό κέντρο.




Σχήμα 5: Membership Functions Before Training




Σχήμα 6: Membership Functions After Training

Η καμπύλη εκπαίδευσης του βέλτιστου μοντέλου φαίνεται παρακάτω. Δεν παρατηρούμε ιδιαίτερη υπερεκπαίδευση από την στιγμή που οι καμπύλες εκπαίδευσης και επικύρωσης είναι αρκετά κοντά η μία στην άλλη.



Σχήμα 7: Learning Curve of Optimal Model

Επιπλέον, εδώ αποτυπώνουμε με έναν λίγο διαφορετικό τρόπο τον πίνακα σφαλμάτων, όμως πριν η έξοδος του νευρωνικού κάνει collapse σε μία συγκεκριμένη ακέραια τιμή μέσω rounding και trimming των τιμών πάνω και κάτω από τις δυνατές τιμές του label. Φαίνεται πως οι τιμές τείνουν να συγκλίνουν προς την ευθεία, η οποία συμβολίζει την ταύτιση των πραγματικών τιμών με τις προβλεπόμενες τιμές, καθώς παρατηρείται μια αυξημένη πυκνότητα σημείων προς εκείνη την διεύθυνση.



Οι πληροφορίες του βέλτιστου μοντέλου βρίσκονται παρακάτω:

Optimal Model

Minimal training RMSE = 1.00779

Minimal checking RMSE = 1.02769

Cluster Radius: 0.20

Number of Features: 20

Number of Rules: 4

Overall Accuracy (OA): 0.4113

Producer's Accuracy (PA): 0.9054, 0.2250, 0.3169, 0.3235, 0.4595

User's Accuracy (UA): 0.7773, 0.0570, 0.6660, 0.5431, 0.0371

$\hat{K}$: 0.2642

335	27	6	2	0
57	27	19	16	1
27	300	315	178	174
10	120	131	252	266
2	0	2	16	17

Πίνακας 6: Error Matrix of Optimal Model

3.3 Σχολιασμός Αποτελεσμάτων

Τα αποτελέσματα του βέλτιστου μοντέλου δεν είναι ιδιαίτερα θετικά με overall accuracy μόλις 0.4113. Σίγουρα είναι καλύτερο από την τυχαία ταξινόμηση (20% accuracy). Περισσότερες πληροφορίες παραθέτονται μαζί με τα αντίστοιχα γραφήματα στα παραρτήματα 3.1 και 3.2.

Τέλος, όπως αναφέραμε στην προηγούμενη εργασία, στην περίπτωση που θέλαμε να προσεγγίσουμε το συγκεκριμένο πρόβλημα με grid partitioning θα είχαμε 20 χαρακτηριστικά και 2 ή 3 ασαφή σύνολα. Αυτό θα οδηγούσε σε 2^{20} ή 3^{20} κανόνες, δηλαδή 1,048,576 ή 3,486,784,401 κανόνες. Η μέθοδος subtractive clustering δημιουργεί κανόνες μόνο εκεί που αναγνωρίζει ότι υπάρχουν δεδομένα. Έτσι αποφεύγουμε την ανάγκη υπολογισμού n-διάστατων κελιών του πλέγματος η πλειονότητα των οποίων δεν θα περιέχουν δεδομένα. Εν τέλει καταλήγουμε σε 4 κανόνες, ασύγκριτα λιγότερους από ότι αν χρησιμοποιούσαμε grid partitioning.